电子科技大学 自动化工程学院

标 准 实 验 报 告

课程名称： 模式识别与机器学习
学院： 深圳（高等） 研究院
专业： 控制工程
学号： 202622280508
姓名： 周子智
职责分工(组队填)：

指导老师： 凡时财

电子科技大学教务处制表

电子科技大学

实验报告

基于 BP 神经网络与支持向量机的男女生分类

一、实验任务与数据准备

1.1 实验目的

本次实验使用身高、体重、鞋码和 50 m 成绩四个特征，分别构建单隐层多层感知机（MLP）和支持向量机（SVM）男女生分类器。MLP 的隐层固定为 3 个结点，前向传播、误差反向传播（BP）与参数更新均自行实现；SVM 调用 scikit-learn 提供的 SVC，考察线性、多项式、径向基和 Sigmoid 四种核。两类方法采用完全相同的五折划分，以灵敏度（SE）、特异度（SP）、准确率（ACC）和 ROC 曲线下面积（AUC）进行评价。

本实验重点分析三个问题：3 个隐层结点对四维输入特征的分类能力，非线性核对 SVM 分类性能的影响，以及较高整体准确率下两类样本的识别差异。报告分别介绍两类方法的实现及实验结果，并结合相同测试折上的配对比较与误判样本分析，讨论模型性能差异及其表现。

1.2 数据检查与处理原则

数据来自课程提供的 pattern_recognition_homework_dataset.xlsx，共 1280 条记录。本实验仅使用性别标签及四个指定特征，编号用于核对样本和交叉验证划分。标签编码固定为女生 0、男生 1。5 条标签缺失或不符合 0/1 编码的记录被排除；另有 1 条记录的四个特征全部缺失，不具备有效输入，因此排除。最终保留 1274 条，其中男生 1018 条、女生 256 条。

训练前按照表 1-1 固定各特征的输入质量范围。缺失、非数值或越界的单个测量值统一记为缺失，含局部缺失特征的记录予以保留。例如，身高 781 cm 和鞋码 58 超出预设范围；50 m 列中的“×”“8，8”“7. .9”等异常字符串缺少可靠的修正依据，均按缺失处理。处理后 20 条样本存在至少一个缺失特征，在每个训练折中分别计算各特征中位数，再用这些中位数填补训练与测试数据。

表 1-1 特征定义、固定质量范围及缺失数量

特征	单位	接受范围	处理后缺失数
身高	cm	130–220	1
体重	kg	30–200	1
鞋码	原始鞋码	30–50	3
50 m 成绩	s	5–20	17

注：范围端点包含在内，缺失数是在最终 1274 条样本中统计，且可发生于同一条记录。上述范围用于统一处理输入质量，其含义限于本实验的数据清洗规则。

范围内的极端值仍按规则保留，例如体重 200 kg。该处理方式独立于类别标签及模型预测结果，处理后的数据仍可能包含录入噪声。全部样本编号唯一，部分记录的四特征及标签组合相同。考虑到测量精度有限，且现有信息无法确认这些记录是否来自同一个体，不同编号的记录均予以保留。因此，本实验的训练集与测试集按编号进行分离。

1.3 特征标准化

身高、体重、鞋码和时间的量纲不同，直接用于梯度更新或距离核会使数值尺度较大的特征占据优势。缺失值填补完成后，采用训练折的均值和总体标准差对各特征进行标准化，并将同一变换应用于对应测试折：

$$z_{ij} = \frac{x_{ij} - \mu_j}{s_j}.$$

其中，μ 和 s 仅由当前训练子集估计。在内层验证中，缺失值填补和标准化参数均由内层训练子集重新拟合，以避免预处理过程引入验证集信息。描述性可视化使用的数据变换单独计算，不进入模型训练或指标评价。

二、统一的五折评价方案

2.1 划分与参数选择

外层采用打乱后的分层五折交叉验证，随机种子设为 23，使每折男、女生比例接近原始比例。每次用四折训练、一折测试，五次结束后，每条样本恰好有一次未参与其对应模型训练的折外预测（OOF）。MLP 与所有 SVM 配置共用这些划分，保证模型之间的差异不是由测试样本变化造成的。

参数选择在每个外层训练集内部进行，同样采用分层五折，以平均 AUC 为选择准则。内层选定参数后，使用整个外层训练集重新拟合模型，再在未参与参数选择的外层测试集上进行评价。该嵌套流程将参数选择与性能评价分离，

降低使用测试结果选择参数所引入的评价偏差[1]。本文的五折结果均指外层评价，内层分数仅用于参数选择。

四种 SVM 核分别完成内层调参并报告外层结果。在此基础上，依据同一批内层候选结果联合选择核函数及其参数，形成“SVM（内层选核）”流程，图表中记为 SVM-selected，并将其作为与 MLP 比较的主要 SVM 方案。该流程在外层测试前完成核函数选择；四种核的外层结果则用于分析不同核函数的性能特征。

2.2 指标定义与汇总方式

全部模型统一以男生为正类。TP 表示男生判为男生，FN 表示男生判为女生，TN 表示女生判为女生，FP 表示女生判为男生。指标计算为：

$$\mathrm{SE}=\frac{TP}{TP+FN},\qquad \mathrm{SP}=\frac{TN}{TN+FP},\qquad \mathrm{ACC}=\frac{TP+TN}{TP+TN+FP+FN}.$$

因此，SE 是男生召回率，SP 是女生召回率。AUC 采用软件包对连续分类分数计算；MLP 使用男生输出概率，SVM 使用 decision_function 的连续判别分数。离散分类采用 MLP 的 0.5 阈值和 SVM 的 0 阈值，不在外层测试集上重新选择阈值。

主表报告五折算术均值与样本标准差。SE、SP、ACC 以百分数表示，AUC 保持 0–1 尺度；标准差反映本次划分下的折间波动，不解释为置信区间。混淆矩阵则汇总 1274 条 OOF 预测，便于查看实际错误人数。AUC 先逐折计算再平均，不把不同折 SVM 模型未经校准的分数直接拼接计算总 AUC。

男生样本约占 79.91%。将全部样本均判为男生时，整体 ACC 仍可达到 79.91%，而 SP 为 0。因此，模型评价除整体 ACC 外，还需结合 SE 与 SP 分析两类样本的识别能力及其差异。

三、BP 神经网络的实现与结果分析

3.1 网络结构与前向传播

MLP 采用 4–3–1 结构：输入为标准化后的四维向量，隐层 3 个结点使用 tanh 激活，输出层 1 个结点使用 Sigmoid 激活。网络共有 19 个可训练参数，分别来自输入到隐层的 12 个权重、3 个隐层偏置、隐层到输出的 3 个权重以及 1 个输出偏置。反向传播通过输出误差逐层计算参数梯度，是训练隐层表征的基础[2]。

对一个含 n 条样本的训练批次，令 Z 为 n×4 输入矩阵，W_1为 4×3 权重矩阵，b_1为 3 维偏置，W_2为 3×1 权重矩阵，b_2为标量。前向计算为：

$$H=\tanh(ZW_1+b_1),\qquad a=HW_2+b_2,\qquad p=\sigma(a)=\frac{1}{1+\exp(-a)}.$$

偏置按样本广播，H 的每行是该样本的 3 维隐层表示。输出 p 用于男生分数排序，达到 0.5 时判为男生。按照作业要求，隐层结点数固定为 3，模型训练及参数选择均在该容量约束下进行。

3.2 损失函数与手写反向传播

训练目标采用二元交叉熵，并仅对权重加入 L2 正则化，偏置不正则化：

$$L=-\frac{1}{n}\sum_{i=1}^{n}\left[y_i\log(p_i)+(1-y_i)\log(1-p_i)\right]+\frac{\lambda}{2}(\|W_1\|_F^2+\|W_2\|_F^2).$$

交叉熵约束输出分数与标签一致，L2 项限制权重过大。实际程序从输出层的原始值 a 计算数值稳定的交叉熵，避免对接近 0 的概率直接取对数。设输出层误差信号为 δ_2，则 Sigmoid 与交叉熵组合后的梯度简化为：

$$\delta_2=\frac{p-y}{n},\qquad \nabla_{W_2}L=H^{\mathsf{T}}\delta_2+\lambda W_2,\qquad \nabla_{b_2}L=\sum_i\delta_{2i}.$$

再将输出误差通过 W_2传回隐层，乘以 tanh 的局部导数，得到：

$$\delta_1=(\delta_2W_2^{\mathsf{T}})\odot(1-H^2),\qquad \nabla_{W_1}L=Z^{\mathsf{T}}\delta_1+\lambda W_1.$$

隐层偏置的梯度由 δ_1沿样本维度求和得到，符号$\odot$表示逐元素相乘。均值因子 1/n 在 δ_2中引入，并通过链式法则传递至隐层梯度。所有梯度均基于同一次前向传播的参数计算，随后统一更新，以保持各层梯度计算所用参数的一致性。

程序采用 NumPy 矩阵运算实现上述梯度计算，不调用神经网络训练器或自动求导工具。采用中心差分法逐一计算 19 个参数的数值梯度，并与解析梯度比较，以检验反向传播实现的一致性。模型的分类能力通过外层测试结果进行评价。

3.3 优化与参数选择

训练使用全批量 Adam 更新。其作用是根据每个参数的梯度一阶、二阶移动平均调整步长，梯度本身仍由上述手写 BP 计算。网络固定训练 800 轮，训练过程中不读取外层测试标签，也不依据外层测试损失早停。候选学习率为 0.01 和 0.03，L2 系数为 0、0.001 和 0.01，共 6 组配置；每组以同一内层五折 AUC 评估，选定后重新训练外层模型。

权重采用 Glorot 均匀初始化，偏置初始化为 0，随机数种子按训练折固定。Adam 的一阶、二阶衰减系数分别为 0.9 和 0.999，数值稳定项为 10^{-8}；程序自行维护两组移动平均并执行偏差校正。全批量意味着一次更新使用当前训练集全部样本，800 轮对应 800 次参数更新。

训练轮数、网络宽度与参数候选范围均在外层评价前固定，使各折结果对应一致的训练与选择流程。内层 AUC 反映候选配置在训练数据内部的验证表现，其排序可能随数据划分变化。因此，性能分析同时报告外层各折结果及折间波动。

3.4 训练检查与五折结果

19 个参数均通过数值梯度检查，最大绝对误差为 1.72×10^{-11}，最大相对误差为 4.79×10^{-10}，表明当前损失函数与手写梯度在检查点上具有较高一致性。图 3-1 显示，五次训练的目标值均由初始值持续降低后逐渐趋缓；初始损失在 0.522–0.879 之间，最终在 0.065–0.134 之间。由于各折采用的正则化系数不同，目标值曲线主要用于分析优化过程的稳定性，模型性能则依据外层测试指标进行比较。

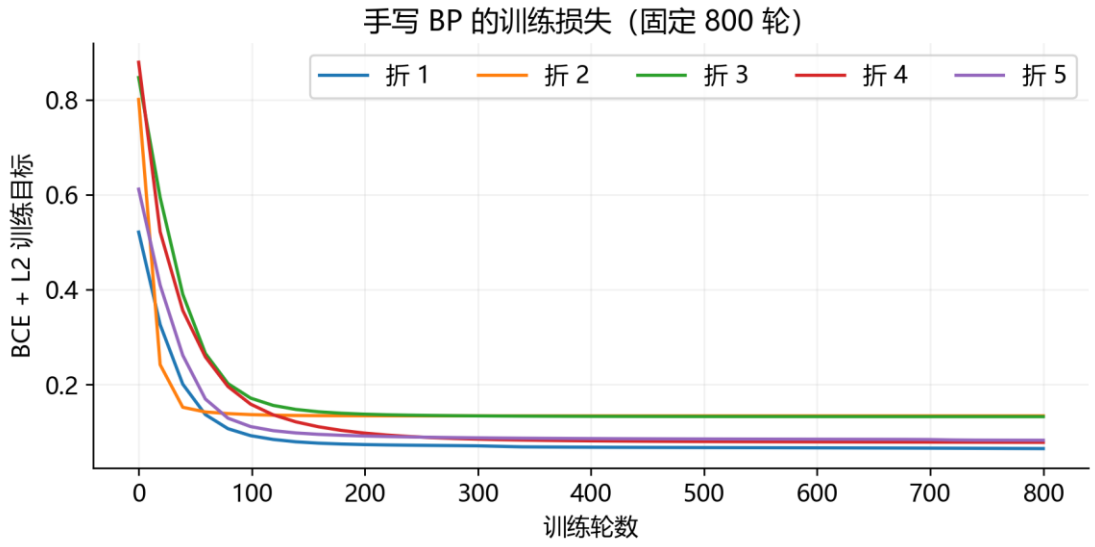


图 3-1 五个外层 MLP 模型的训练目标曲线

五折依次选出的“L2 系数，学习率”为（0，0.01）、（0.01，0.03）、（0.01，0.01）、（0.001，0.01）和（0.001，0.01）。各训练子集选择的配置存在差异，表明当前候选范围内未出现五折均占优的同一组参数。表 3-1 列出各折测试结果。

表 3-1 MLP 的外层五折测试结果

折	SE（%）	SP（%）	ACC（%）	AUC
1	98.04	92.16	96.86	0.9859
2	98.53	98.04	98.43	0.9950
3	98.53	94.12	97.65	0.9904
4	98.03	94.23	97.25	0.9865
5	99.01	94.12	98.03	0.9920
均值±标准差	98.43±0.41	94.53±2.14	97.65±0.62	0.9900±0.0038

由表 3-1 可见，隐层仅含 3 个结点的网络取得了 97.65%的平均 ACC 和 0.9900 的平均 AUC，表明四维输入包含较强的分类信息，较小规模的网络能够有效提取这些信息。训练 ACC 均值为 97.78%，比测试高 0.14 个百分点；训练 AUC 为 0.9919，比测试高约 0.0020。训练与测试指标差距较小，模型在本次数据划分下表现出较好的一致性，其在独立数据上的表现仍有待验证。

进一步比较类别指标，SE 为 98.43%，高于 SP 的 94.53%。OOF 结果中，14/256 名女生被判为男生，16/1018 名男生被判为女生。两类误判人数接近，但女生样本的误判比例更高。第 2 折错判 1 名女生，SP 为 98.04%；第 1 折错判 4 名女生，SP 降至 92.16%。各折女生样本数仅为 51 或 52，一条女生样本的分类结果变化即可使该折 SP 变化约 1.9 个百分点，这有助于解释 SP 较大的折间波动。

上述结果表明，较高的整体准确率仍可能伴随两类样本识别能力的差异。平均损失由全部样本共同贡献，数量较多的男生样本在优化中占比较大；同时，两类样本的特征分布存在重叠。这些因素均可能影响默认阈值下的类别表现。由于本实验未分别调整类别权重或分类阈值，各因素对性能差异的具体影响尚无法独立确定。

四、SVM 的实现与不同核函数分析

4.1 分类原理与实现

SVM 通过间隔约束和误分类惩罚确定决策边界，核函数则允许在不显式展开高维特征的情况下构造非线性分类器[3]。将标签写成 $t_i=2y_i-1$，软间隔 SVM 的优化目标为：

$$\min_{w,b,\xi} \frac{1}{2}\| w\|^2 + C\sum_i \xi_i, \quad t_i[w^{\mathrm{T}}\phi(z_i)+b] \ge 1-\xi_i, \quad \xi_i \ge 0.$$

其中，C 控制对间隔违反的惩罚强度，φ 表示核所对应的特征映射。C 较大时更重视训练样本上的间隔约束，但并不意味着测试表现一定更好。最终判别分数由支持向量与待测样本之间的核值加权求和得到：

$$f(z)=\sum_{i\in \mathrm{SV}} \alpha_i t_i K(z_i,z)+b, \qquad \hat{y}=\mathbf{1}[f(z)\geq 0].$$

实验使用 scikit-learn 1.7.2 的 SVC，底层调用 libsvm 求解[4]。模型与中位数填补、标准化组成同一训练流程，确保每个内层、外层训练子集都独立拟合预处理。SVM 的判别分数用于 AUC，不解释为类别概率，也不额外开启概率校准。

4.2 四种核与候选设置

线性核直接利用标准化后的内积；多项式核通过幂次引入特征交互；RBF 核根据样本间距离构建局部相似性；Sigmoid 核对内积施加饱和非线性。四种核分别写为：

$$K_{\mathrm{linear}}(u,v)=u^{\mathsf{T}}v, \qquad K_{\mathrm{poly}}(u,v)=(\gamma u^{\mathsf{T}}v+r)^{d}.$$

$$K_{\mathrm{RBF}}(u,v)=\exp(-\gamma \| u-v \|^{2}), \qquad K_{\mathrm{sigmoid}}(u,v)=\tanh(\gamma u^{\mathsf{T}}v+r).$$

Sigmoid 形式对任意数据和参数不一定满足核矩阵半正定条件[5]，其优化性质受具体数据与参数设置影响。本实验将其作为 SVC 支持的一种比较配置，通过外层测试结果分析其分类表现。

表 4-1 给出训练前确定的搜索范围。所有核均使用相同的 C 候选值，非线性核使用相同的 γ 候选值；多项式阶数固定为 3。参数以内层平均 AUC 选择，而非以训练准确率选择。

表 4-1 SVM 核函数及内层候选参数

核函数	C	γ	固定参数	配置数
线性	0.1、1、10	不使用	不使用	3
多项式	0.1、1、10	0.1、0.25、1	d=3，r=1	9
RBF	0.1、1、10	0.1、0.25、1	不使用	9
Sigmoid	0.1、1、10	0.1、0.25、1	r=0	9

注：各核均采用默认类别权重。SVM（内层选核）在上述 30 组配置的内层结果中联合选择核和参数。SVM 与 MLP 的候选数量不同，性能比较对应各自预设搜索范围下的完整训练流程，未施加等计算量约束。

4.3 不同核函数的结果

表 4-2 汇总了四种核在同一组外层测试折上的指标。RBF 的平均 AUC 最高，为 0.9911；线性核的 ACC 和 SP 最高，分别为 97.65%和 94.14%。不同指标对应的核函数排序存在差异，后续分别从分数排序能力与默认阈值下的分类错误两个方面展开分析。

表 4-2 四种 SVM 核的外层五折结果（均值±样本标准差）

核函数	SE（%）	SP（%）	ACC（%）	AUC
线性	98.53±0.49	94.14±2.40	97.65±0.62	0.9906±0.0046
RBF	98.62±0.64	92.96±2.64	97.49±0.86	0.9911±0.0053
多项式	98.33±0.44	93.75±2.91	97.41±0.59	0.9888±0.0046
Sigmoid	98.13±0.41	92.57±3.78	97.02±0.76	0.9899±0.0049

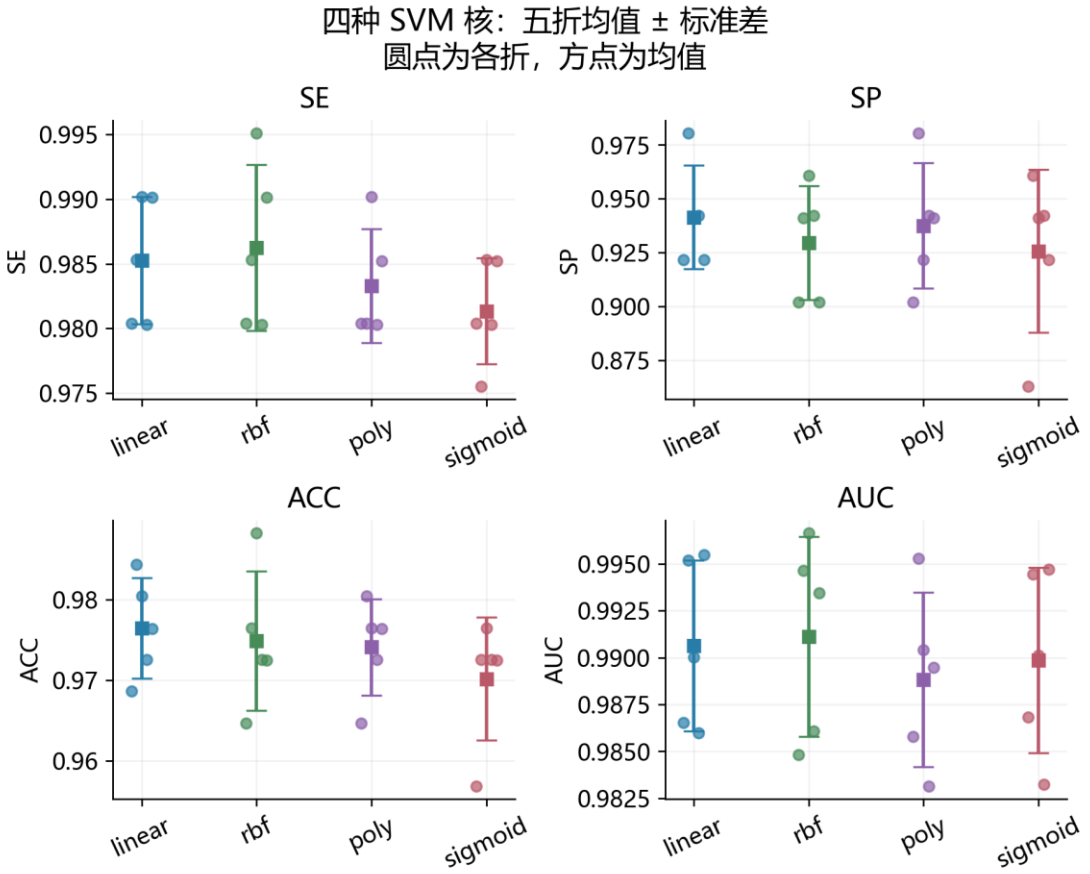


图 4-1 各核的逐折指标与均值、标准差

4.4 核函数效果的讨论

线性核的平均 AUC 仅比 RBF 低约 0.0005，ACC 略高；其 OOF 总误判为 30 条，RBF 为 32 条。该结果表明，标准化后的四维特征能够通过线性边界实现较好的区分，增加非线性表达并未在全部评价指标上带来改善。

RBF 的 SE 略高，但 SP 比线性核低 1.18 个百分点。对应 OOF 计数，RBF 比线性核少错判 1 名男生，多错判 3 名女生，表明其在 0 阈值下具有更高的男生召回率和更低的女生召回率，而较高的 AUC 反映了总体排序能力的略微提升。内层五次联合选核均选中 RBF，因此主比较中的 SVM（内层选核）与本次 RBF 结果一致。其五折（C，γ）依次为（1，0.1）、（0.1，0.1）、（1，0.1）、（1，0.1）、（0.1，0.25），较大的 C 和 γ 均未被选中。

三次多项式核的平均 ACC 为 97.41%、AUC 为 0.9888，在本次候选范围内均低于线性核。多项式交互扩展了模型的表达形式，但未带来稳定的外层性能提升。该差异对应当前核函数形式、固定阶数及搜索范围的组合设置，各因素的独立作用尚不明确。其训练 AUC 均值约 0.9926，测试约 0.9888，表明训练拟合程度高于外层测试表现，仅依据训练指标进行评价会高估实际分类能力。

Sigmoid 核的平均 ACC 最低，为 97.02%，SP 的折间标准差最大，为 3.78 个百分点；第 1 折 7/51 名女生被错判，SP 为 86.27%。其平均 AUC 仍达到 0.9899，高于多项式核的 0.9888，进一步体现了分数排序能力与固定阈值分类准确率之间的差异。本实验未检查核矩阵谱，也未进一步扩大参数搜索范围，因此 Sigmoid 核的半正定性与当前性能之间的具体关系尚不明确。

综合四种核的结果，ACC 差异不足 0.7 个百分点，AUC 均接近 0.99。线性核能够构成有效的分类基准，RBF 则在当前内层 AUC 选择规则下于五折中均被选中。核函数选择需结合评价目标：AUC 侧重分数排序能力，SE、SP 与 ACC 则反映固定阈值下的类别识别与总体分类表现。

五、两种方法的对比与误判分析

5.1 整体性能与逐折配对比较

表 5-1 直接比较 MLP 与 SVM（内层选核）。MLP 的 ACC 高 0.16 个百分点、SP 高 1.57 个百分点；SVM 的 SE 高 0.20 个百分点、AUC 高 0.0012。差异方向随指标变化，没有一个方法在四项指标上同时占优。

表 5-1 两种完整训练流程的外层五折结果

方法	SE（%）	SP（%）	ACC（%）	AUC
MLP-BP	98.43±0.41	94.53±2.14	97.65±0.62	0.9900±0.0038
SVM-selected	98.62±0.64	92.96±2.64	97.49±0.86	0.9911±0.0053

为分析平均指标差异的来源，进一步对相同测试折上的结果进行配对比较。如表 5-2 所示，SVM 在第 3 折的 AUC 比 MLP 高 0.00625，而在第 1、2、4 折略低；五折中仅有两折 AUC 高于 MLP。SVM 的平均 AUC 优势主要受到第 3 折较大增益的影响，该优势未在各折中一致出现。ACC 方面，SVM 一折更高、一折相同、三折更低。

表 5-2 相同测试折上的差值（SVM 减 MLP）

折	ΔSE（百分点）	ΔSP（百分点）	ΔACC（百分点）	ΔAUC
1	0.00	−1.96	−0.39	−0.00106
2	0.00	−3.92	−0.78	−0.00038
3	+0.98	+1.96	+1.18	+0.00625
4	0.00	0.00	0.00	−0.00047
5	0.00	−3.92	−0.79	+0.00145

五折训练集之间存在重叠，逐折差值具有相关性，其统计含义不同于五次独立重复实验。当前结果反映了两种方法接近的分类表现及默认阈值下的类别识别差异，尚不足以确定统计显著的性能优势。图 5-1 给出了两种方法的 OOF 混淆矩阵：MLP 共误判 30 条，SVM 共误判 32 条。SVM 比 MLP 少错判 2 名男生，多错判 4 名女生，与其 SE 略高、SP 和 ACC 较低的指标变化一致。

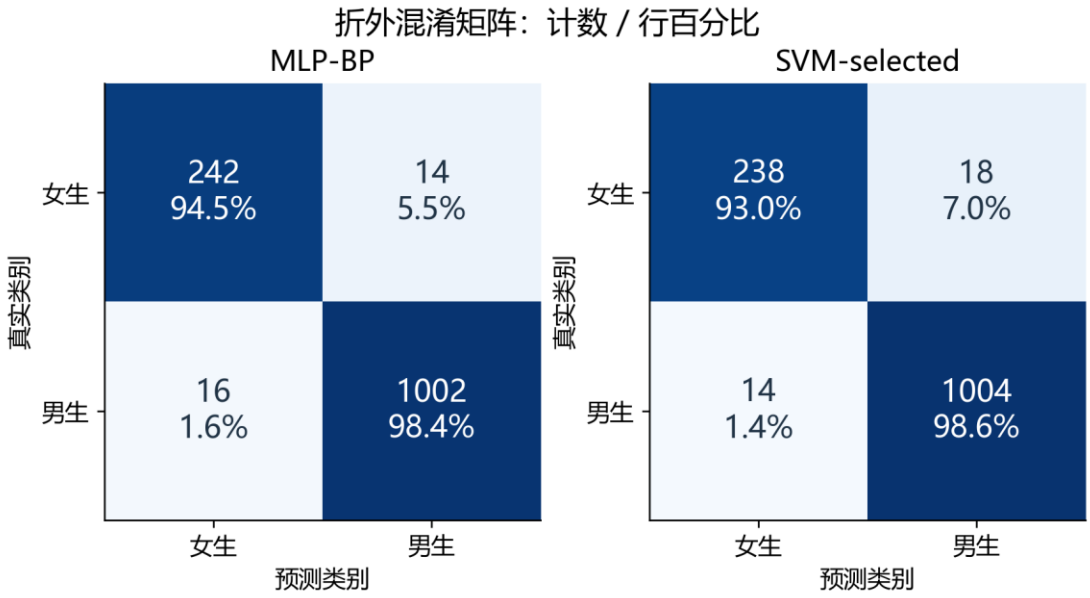


图 5-1 MLP 与 SVM 的 OOF 混淆矩阵，单元格显示人数及行百分比

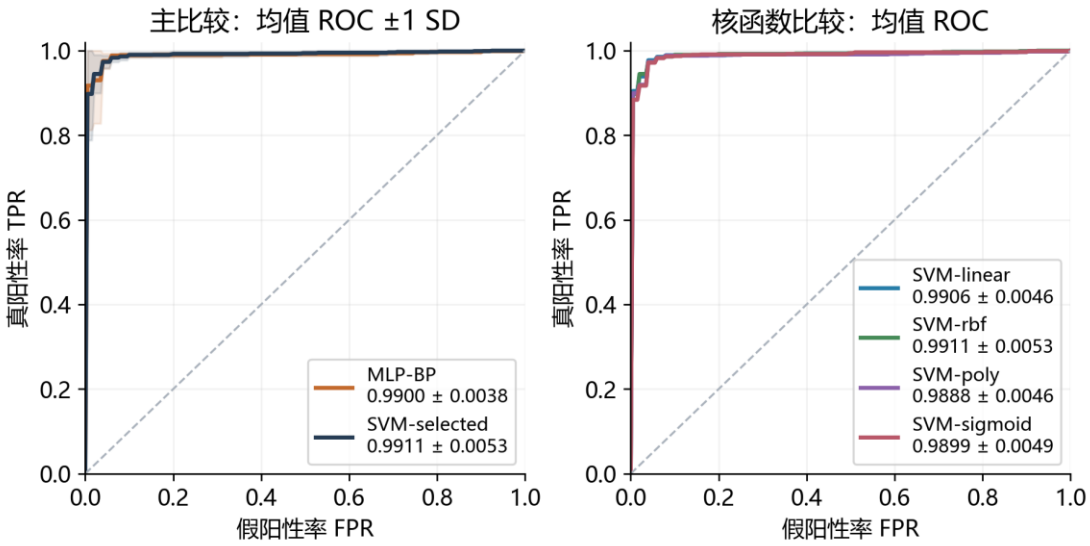


图 5-2 五折平均 ROC 曲线；左侧阴影为折间±1 标准差

图 5-2 中两种方法的平均 ROC 曲线接近，均在较低假阳性率下达到较高真阳性率。图例报告原始五个 AUC 的均值和标准差；平均曲线由各折 ROC 在相同假阳性率网格上插值后取均值得到。阴影表示各折曲线的标准差，用于描述划分引起的波动，不具有独立重复实验置信带或显著性检验的含义。

5.2 误判重叠与样本特征分析

将两种模型的 OOF 结果按样本逐条对齐，得到表 5-3。26 条样本被两种方法共同误判，占 MLP 全部 30 条误判的 86.7%，占 SVM 全部 32 条误判的 81.3%。仅有 10 条样本的分类正确性在两种方法之间存在差异，表明分类器选择对部分样本产生影响，而多数误判集中于两种方法共同识别错误的样本。

表 5-3 两种方法的 OOF 错误重叠

判断情况	女生	男生	合计
两者均正确	237	1001	1238
仅 MLP 错误	1	3	4
仅 SVM 错误	5	1	6
两者均错误	13	13	26

共同误判的 13 名女生，其平均身高 167.92 cm、体重 58.54 kg、鞋码 39.50、50 m 成绩 7.87 s；共同判断正确的女生相应均值为 163.04 cm、51.68 kg、37.29 和 8.97 s。共同误判的女生在这些均值上更接近男生特征方向。共同误判的 13 名男生则平均身高 162.62 cm、体重 52.00 kg、鞋码 37.38、50 m 成绩 8.55 s，呈现相反方向。各特征均值根据对应列的有效观测计算，用于描述误判样本的分布特点，不涉及标签正确性的判定。

进一步分析具体误判记录，匿名行号 row_0022 的标签为男生，四特征为（156 cm，47 kg，36 码，9.5 s），两种方法均判为女生；row_0089 的标签为女生，特征为（166 cm，56 kg，40 码，8.5 s），两者均判为男生。上述案例表明，模型依据四特征的组合模式进行判别，当前输入仍存在难以正确识别的个体。特征分布重叠、测量误差及标签噪声均可能导致此类误判，现有实验尚无法区分各因素的具体影响。

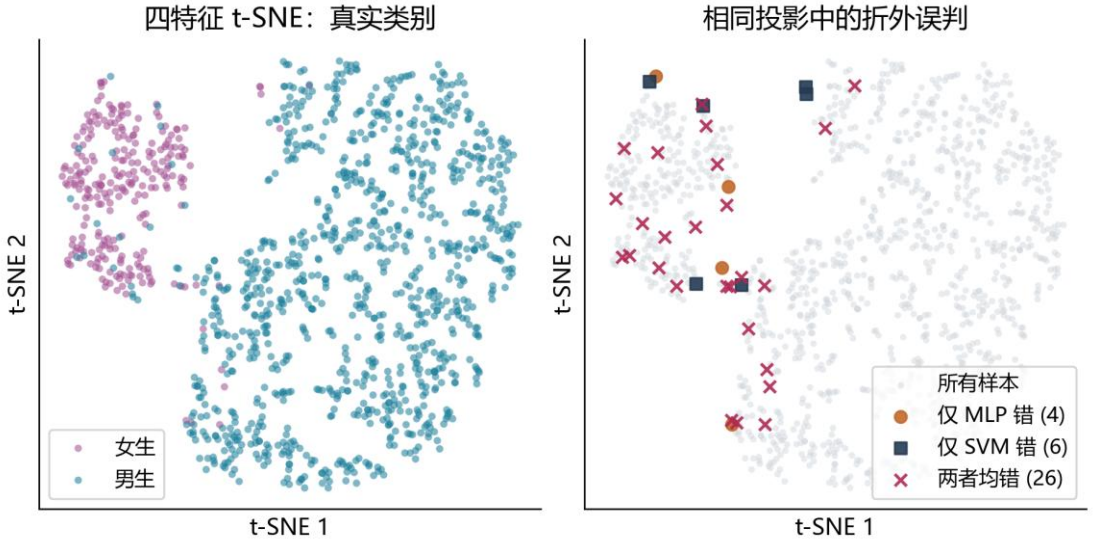


图 5-3 四特征的 t-SNE 描述性投影与相同坐标上的 OOF 误判

图 5-3 左侧呈现两个主要类别区域，少量样本分布于另一类别的主要区域内；右侧在相同坐标上叠加共同误判与各方法单独误判，用于结合错误重叠统计分析样本分布。t-SNE 采用独立填补、标准化后的原始四特征进行描述性降

维，所得二维坐标仅用于可视化，不参与分类器训练、调参或指标计算。二维投影与模型的实际决策空间不同，图中间距及区域形状仅作定性解释。

t-SNE 的困惑度设为 30，采用 PCA 初始化和自动学习率，迭代 1000 次，随机种子为 23。图中标签只用于着色，错误标记来自已经完成的 OOF 预测。

5.3 结果适用范围

本次结果基于同一份课程数据及固定随机种子下的嵌套五折交叉验证。输入质量规则保留了范围内极端值，数据中缺少更细的个体来源信息，参数搜索也限定于预设网格。在此条件下，两种方法均取得了较好的分类表现；其性能排序对其他人群、数据划分和参数范围的适用性仍需进一步验证。

后续可通过增加独立测试数据或重复外层划分，进一步分析两种方法之间较小性能差异的稳定性。对于更重视女生识别的应用需求，可在训练数据内部评估类别权重与分类阈值调整的作用。

六、实验总结

本实验实现了采用手写反向传播的 4–3–1 神经网络及四种核函数的 SVM 分类器，并在统一的五折评价框架下比较其性能。数值梯度校验验证了 BP 梯度计算的一致性，训练曲线呈现出目标值持续下降并逐渐趋缓的优化过程。SVM 的核函数比较表明，非线性形式扩展了决策边界的表达能力，但在当前数据与候选范围内未必减少测试错误。

在主比较中，MLP 的平均 ACC 为 97.65%、AUC 为 0.9900；内层选核 SVM 的平均 ACC 为 97.49%、AUC 为 0.9911。MLP 在默认阈值下具有较高的女生召回率，SVM 的平均排序能力略高，但该优势未在全部测试折中一致出现。两种方法共同误判 26 条样本，表明多数错误集中于相同的困难样本。因此，两类方法的性能差异需要结合分数排序、类别识别及划分波动综合分析，当前结果尚未体现某一方法在各项指标上的一致优势。

Notebook 保存了完整实现、运行输出和结果图表；五折划分、候选搜索分数、逐条 OOF 预测与数据文件哈希同时保存于 results/homework2，便于复核报告中的统计量。实验使用 Python 3.10.19、NumPy 2.2.6、scikit-learn 1.7.2，基础随机种子为 23。

参考文献

[1] scikit-learn developers. Nested versus non-nested cross-validation[EB/OL]. scikit-learn 1.7.2 documentation. https://scikit-learn.org/1.7/auto_examples/model_selection/plot_nested_cross_validation_iris.html（访问日期：2026-10-13）.

[2] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. Nature, 1986, 323: 533–536. DOI: 10.1038/323533a0.

[3] Cortes C, Vapnik V. Support-vector networks[J]. Machine Learning, 1995, 20: 273–297. DOI: 10.1007/BF00994018.

[4] scikit-learn developers. SVC[EB/OL]. scikit-learn 1.7.2 documentation. https://scikit-learn.org/1.7/modules/generated/sklearn.svm.SVC.html（访问日期：2026-10-13）.

[5] LIBSVM authors. LIBSVM FAQ: How do I choose the kernel?[EB/OL]. https://www.csie.ntu.edu.tw/~cjlin/libsvm/faq.html（访问日期：2026-10-13）.