电子科技大学 自动化工程学院

标 准 实 验 报 告

课程名称： 模式识别与机器学习
学院： 深圳（高等） 研究院
专业： 控制工程
学号： 202622280508
姓名： 周子智
职责分工(组队填)：

指导老师： 凡时财

电子科技大学教务处制表

电子科技大学

实验报告

基于 BP 神经网络与支持向量机的男女生分类

一、实验任务与数据准备

1.1 实验目的

本次实验使用身高、体重、鞋码和 50 m 成绩四个特征，分别构建单隐层多层感知机（MLP）和支持向量机（SVM）男女生分类器。MLP 的隐层固定为 3 个结点，前向传播、误差反向传播（BP）与参数更新均自行实现；SVM 调用 scikit-learn 提供的 SVC，考察线性、多项式、径向基和 Sigmoid 四种核。两类方法采用完全相同的五折划分，以灵敏度（SE）、特异度（SP）、准确率（ACC）和 ROC 曲线下面积（AUC）进行评价。

我希望通过实验回答三个问题：3 个隐层结点能否在这组四维特征上学到有效的分类边界；SVM 增加非线性后是否一定改善结果；当整体准确率较高时，男生和女生是否都得到了较好的识别。为此，报告把方法实现与各自结果放在同一章，再结合配对折结果和具体误判讨论两类方法的差异。

1.2 数据检查与处理原则

数据来自课程提供的 pattern_recognition_homework_dataset.xlsx，共 1280 条记录。本实验仅使用性别标签及四个指定特征，编号用于核对样本和交叉验证划分。标签编码固定为女生 0、男生 1。5 条标签缺失或不符合 0/1 编码的记录被排除；另有 1 条记录的四个特征全部缺失，不具备有效输入，因此排除。最终保留 1274 条，其中男生 1018 条、女生 256 条。

我在训练前固定了表 1-1 中的输入质量范围。缺失、非数值或越界的单个测量值统一记为缺失，不因一个特征有问题而删除整条记录。例如，身高 781 cm 和鞋码 58 超出范围；50 m 列中的“×”“8，8”“7. .9”等没有直接猜测修正。处理后 20 条样本存在至少一个缺失特征，在每个训练折中分别计算各特征中位数，再用这些中位数填补训练与测试数据。

表 1-1 特征定义、固定质量范围及缺失数量

特征	单位	接受范围	处理后缺失数
身高	cm	130–220	1
体重	kg	30–200	1
鞋码	原始鞋码	30–50	3
50 m 成绩	s	5–20	17

注：范围端点包含在内，缺失数是在最终 1274 条样本中统计，且可发生于同一条记录。范围是本实验统一执行的质量规则，不代表经过验证的生理学界限。

范围内的极端值仍按规则保留，例如体重 200 kg。这使处理过程不依赖类别或模型预测结果，但也意味着保留的数据仍可能含有录入噪声。全部编号唯一；相同的四特征和标签存在重复组合，由于记录精度有限且没有证据说明它们来自同一人，我没有据此删去不同编号的记录。本实验因此只保证编号层面的训练与测试分离。

1.3 特征标准化

身高、体重、鞋码和时间的量纲不同，直接用于梯度更新或距离核会使数值尺度较大的特征占据优势。填补之后，我用训练折的均值和总体标准差将每列标准化，并把同一变换应用到对应测试折：

$$z_{ij} = \frac{x_{ij} - \mu_j}{s_j}.$$

其中，μ 和 s 仅由当前训练子集估计。在内层验证中，填补和标准化也重新从内层训练子集拟合，不能先对整个数据集做标准化再划分。描述性可视化使用的数据变换单独计算，不进入模型训练或指标评价。

二、统一的五折评价方案

2.1 划分与参数选择

外层采用打乱后的分层五折交叉验证，随机种子设为 23，使每折男、女生比例接近原始比例。每次用四折训练、一折测试，五次结束后，每条样本恰好有一次未参与其对应模型训练的折外预测（OOF）。MLP 与所有 SVM 配置共用这些划分，保证模型之间的差异不是由测试样本变化造成的。

参数选择放在每个外层训练集内部，同样采用分层五折，以平均 AUC 为选择准则。内层选定参数后，用整个外层训练集重新拟合，再评估此前未使用的外层测试集。这样区分“选参数”和“评性能”两个环节，避免用同一组测试结果

同时完成两件事[1]。本文所说的五折结果均指外层评价，内层分数只用于参数选择。

四种 SVM 核各自完成内层调参并报告外层结果。此外，我在同一批内层候选结果中联合选择核及参数，形成“SVM（内层选核）”流程，图表中记为 SVM-selected，用它与 MLP 进行主比较。这个流程在每个外层测试前已经确定核函数；四核表用于理解核的行为，不将外层表现最好的核重新包装成事先选定的模型。

2.2 指标定义与汇总方式

全部模型统一以男生为正类。TP 表示男生判为男生，FN 表示男生判为女生，TN 表示女生判为女生，FP 表示女生判为男生。指标计算为：

$$\mathrm{SE}=\frac{TP}{TP+FN},\qquad \mathrm{SP}=\frac{TN}{TN+FP},\qquad \mathrm{ACC}=\frac{TP+TN}{TP+TN+FP+FN}.$$

因此，SE 是男生召回率，SP 是女生召回率。AUC 采用软件包对连续分类分数计算；MLP 使用男生输出概率，SVM 使用 decision_function 的连续判别分数。离散分类采用 MLP 的 0.5 阈值和 SVM 的 0 阈值，不在外层测试集上重新选择阈值。

主表报告五折算术均值与样本标准差。SE、SP、ACC 以百分数表示，AUC 保持 0–1 尺度；标准差反映本次划分下的折间波动，不解释为置信区间。混淆矩阵则汇总 1274 条 OOF 预测，便于查看实际错误人数。AUC 先逐折计算再平均，不把不同折 SVM 模型未经校准的分数直接拼接计算总 AUC。

男生约占 79.91%。即使将所有样本都判成男生，整体 ACC 也能达到 79.91%，但此时 SP 为 0。因此，我会重点检查 SE 与 SP 是否均衡，而不是仅凭 ACC 判断模型是否有效。

三、BP 神经网络的实现与结果分析

3.1 网络结构与前向传播

MLP 采用 4–3–1 结构：输入为标准化后的四维向量，隐层 3 个结点使用 tanh 激活，输出层 1 个结点使用 Sigmoid 激活。网络共有 19 个可训练参数，分别来自输入到隐层的 12 个权重、3 个隐层偏置、隐层到输出的 3 个权重以及 1 个输出偏置。反向传播通过输出误差逐层计算参数梯度，是训练隐层表征的基础[2]。

对一个含 n 条样本的训练批次，令 Z 为 n×4 输入矩阵，W_1为 4×3 权重矩阵，b_1为 3 维偏置，W_2为 3×1 权重矩阵，b_2为标量。前向计算为：

$$H=\tanh(ZW_1+b_1),\qquad a=HW_2+b_2,\qquad p=\sigma(a)=\frac{1}{1+\exp(-a)}.$$

偏置按样本广播，H 的每行是该样本的 3 维隐层表示。输出 p 用于男生分数排序，达到 0.5 时判为男生。3 个隐层结点是作业规定的容量约束，本实验没有通过增加隐层宽度改善结果。

3.2 损失函数与手写反向传播

训练目标采用二元交叉熵，并仅对权重加入 L2 正则化，偏置不正则化：

$$L=-\frac{1}{n}\sum_{i=1}^{n}\left[y_i\log(p_i)+(1-y_i)\log(1-p_i)\right]+\frac{\lambda}{2}(\|W_1\|_F^2+\|W_2\|_F^2).$$

交叉熵约束输出分数与标签一致，L2 项限制权重过大。实际程序从输出层的原始值 a 计算数值稳定的交叉熵，避免对接近 0 的概率直接取对数。设输出层误差信号为 δ_2，则 Sigmoid 与交叉熵组合后的梯度简化为：

$$\delta_2=\frac{p-y}{n},\qquad \nabla_{W_2}L=H^{\mathsf{T}}\delta_2+\lambda W_2,\qquad \nabla_{b_2}L=\sum_i\delta_{2i}.$$

再将输出误差通过 W_2传回隐层，乘以 tanh 的局部导数，得到：

$$\delta_1=(\delta_2W_2^{\mathsf{T}})\odot(1-H^2),\qquad \nabla_{W_1}L=Z^{\mathsf{T}}\delta_1+\lambda W_1.$$

隐层偏置的梯度是 δ_1沿样本维度求和，符号⊙表示逐元素相乘。这里的均值因子 1/n 只在 δ_2中引入一次，传回前一层时不能再次除以 n。所有梯度都基于同一次前向传播的旧参数计算完成，再统一更新参数，避免提前更新 W_2改变隐层梯度。

程序只使用 NumPy 矩阵运算实现这条梯度链，没有调用神经网络训练器或自动求导工具。为检查实现，我对 19 个参数逐一进行中心差分，把扰动参数后的损失变化与解析梯度比较；这一检查验证的是梯度实现的一致性，最终分类能力仍由外层测试评价。

3.3 优化与参数选择

训练使用全批量 Adam 更新。其作用是根据每个参数的梯度一阶、二阶移动平均调整步长，梯度本身仍由上述手写 BP 计算。网络固定训练 800 轮，训练过程中不读取外层测试标签，也不依据外层测试损失早停。候选学习率为 0.01 和 0.03，L2 系数为 0、0.001 和 0.01，共 6 组配置；每组以同一内层五折 AUC 评估，选定后重新训练外层模型。

权重采用 Glorot 均匀初始化，偏置初始化为 0，随机数种子按训练折固定。Adam 的一阶、二阶衰减系数分别为 0.9 和 0.999，数值稳定项为 10^{-8}；程序自行维护两组移动平均并执行偏差校正。全批量意味着一次更新使用当前训练集全部样本，800 轮对应 800 次参数更新。

我把训练轮数、网络宽度和候选范围固定下来，是为了让外层评价保持明确含义。内层分数高说明配置在训练数据内部较合适，但不保证外层测试也最好；因此报告保留各折结果及其波动，而不只展示最优一次运行。

3.4 训练检查与五折结果

19 个参数的数值梯度检查全部通过，最大绝对误差为 1.72×10^{-11}，最大相对误差为 4.79×10^{-10}。这说明当前损失函数与手写梯度在检查点上相符。图 3-1 显示，五次训练的目标值均由初始值持续降低后逐渐趋缓；初始损失在 0.522–0.879 之间，最终在 0.065–0.134 之间。各折的正则化系数并不相同，因此我主要据此判断优化过程是否稳定，而不把最终损失最低的一折直接当作性能最好的一折。

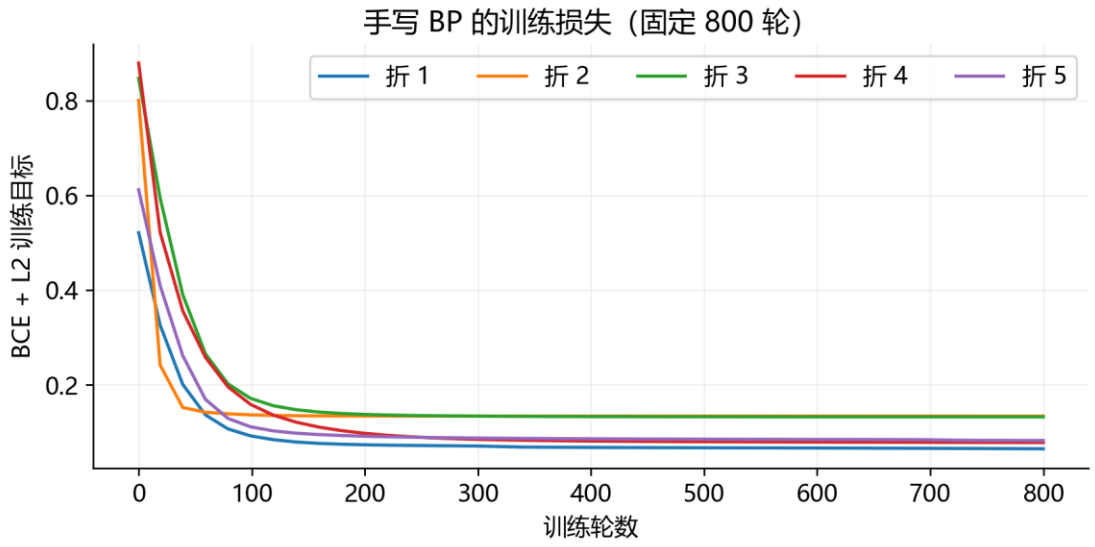


图 3-1 五个外层 MLP 模型的训练目标曲线

五折依次选出的“L2 系数，学习率”为（0，0.01）、（0.01，0.03）、（0.01，0.01）、（0.001，0.01）和（0.001，0.01）。不同训练子集选择不同配置，说明在这份数据上并不存在每折都占优的同一组参数。表 3-1 列出各折测试结果。

表 3-1 MLP 的外层五折测试结果

折	SE（%）	SP（%）	ACC（%）	AUC
1	98.04	92.16	96.86	0.9859
2	98.53	98.04	98.43	0.9950
3	98.53	94.12	97.65	0.9904
4	98.03	94.23	97.25	0.9865
5	99.01	94.12	98.03	0.9920
均值±标准差	98.43±0.41	94.53±2.14	97.65±0.62	0.9900±0.0038

我首先关注到，只有 3 个隐层结点的网络已经取得 97.65%的平均 ACC 和 0.9900 的平均 AUC，说明这组四维输入能够提供较强的分类信息，较小的网络也能利用这些信息。训练 ACC 均值为 97.78%，只比测试高 0.14 个百分点；训练 AUC 为 0.9919，比测试高约 0.0020。本次结果没有出现很大的训练与测试落差，但这不能替代新数据上的外部验证。

其次，SE 为 98.43%，仍高于 SP 的 94.53%。从 OOF 计数看，14/256 名女生被判为男生，16/1018 名男生被判为女生：两类误判人数接近，女生的误判比例却更高。第 2 折只错判 1 名女生，第 1 折错判 4 名女生，SP 因此从 98.04%降到 92.16%。每折只有 51 或 52 名女生，一个女生样本的判断变化就会使该折 SP 变化约 1.9 个百分点，所以 SP 波动大于 SE 并不令人意外。

这个现象也改变了我对高准确率的理解。平均损失由所有样本共同贡献，样本较多的男生在优化中占比更大；同时两类特征存在重叠。二者都可能影响默认阈值下的类别表现，但本实验没有单独改变类别权重或阈值，不能把差异完全归因于其中一个因素。

四、SVM 的实现与不同核函数分析

4.1 分类原理与实现

SVM 通过间隔约束和误分类惩罚确定决策边界，核函数则允许在不显式展开高维特征的情况下构造非线性分类器[3]。将标签写成 $t_i=2y_i-1$，软间隔 SVM 的优化目标为：

$$\min_{w,b,\xi} \frac{1}{2}\|w\|^2 + C\sum_i \xi_i, \quad t_i[w^{\mathsf{T}}\phi(z_i)+b] \ge 1-\xi_i, \quad \xi_i \ge 0.$$

其中，C 控制对间隔违反的惩罚强度，φ 表示核所对应的特征映射。C 较大时更重视训练样本上的间隔约束，但并不意味着测试表现一定更好。最终判别分数由支持向量与待测样本之间的核值加权求和得到：

$$f(z)=\sum_{i\in \mathrm{SV}} \alpha_i t_i K(z_i,z)+b, \qquad \hat{y}=\mathbf{1}[f(z)\geq 0].$$

实验使用 scikit-learn 1.7.2 的 SVC，底层调用 libsvm 求解[4]。模型与中位数填补、标准化组成同一训练流程，确保每个内层、外层训练子集都独立拟合预处理。SVM 的判别分数用于 AUC，不解释为类别概率，也不额外开启概率校准。

4.2 四种核与候选设置

线性核直接利用标准化后的内积；多项式核通过幂次引入特征交互；RBF 核根据样本间距离构建局部相似性；Sigmoid 核对内积施加饱和非线性。四种核分别写为：

$$K_{\mathrm{linear}}(u,v)=u^{\top}v, \qquad K_{\mathrm{poly}}(u,v)=(\gamma u^{\top}v+r)^{d}.$$

$$K_{\mathrm{RBF}}(u,v)=\exp(-\gamma \| u-v \|^{2}), \qquad K_{\mathrm{sigmoid}}(u,v)=\tanh(\gamma u^{\top}v+r).$$

Sigmoid 形式对任意数据和参数不一定满足核矩阵半正定条件[5]，因此不能直接套用前三种核的标准凸优化解释。本实验将其作为 SVC 支持的一种比较配置，以实际外层表现评价。

表 4-1 给出训练前确定的搜索范围。所有核均使用相同的 C 候选值，非线性核使用相同的 γ 候选值；多项式阶数固定为 3。参数以内层平均 AUC 选择，而非以训练准确率选择。

表 4-1 SVM 核函数及内层候选参数

核函数	C	γ	固定参数	配置数
线性	0.1、1、10	不使用	不使用	3
多项式	0.1、1、10	0.1、0.25、1	d=3，r=1	9
RBF	0.1、1、10	0.1、0.25、1	不使用	9
Sigmoid	0.1、1、10	0.1、0.25、1	r=0	9

注：各核不使用类别权重调整。SVM（内层选核）在上述 30 组配置的内层结果中联合选择核和参数。候选数量与 MLP 不完全一致，因此本实验比较的是已说明搜索范围下的完整训练流程，而不是严格等计算量的搜索策略。

4.3 不同核函数的结果

表 4-2 汇总了四个核在同一组外层测试折上的指标。RBF 的平均 AUC 最高，为 0.9911；线性核的 ACC 和 SP 最高，分别为 97.65%和 94.14%。这两个排序并不相同，因此我分别讨论分数排序能力与默认阈值下的分类错误。

表 4-2 四种 SVM 核的外层五折结果（均值±样本标准差）

核函数	SE（%）	SP（%）	ACC（%）	AUC
线性	98.53±0.49	94.14±2.40	97.65±0.62	0.9906±0.0046
RBF	98.62±0.64	92.96±2.64	97.49±0.86	0.9911±0.0053
多项式	98.33±0.44	93.75±2.91	97.41±0.59	0.9888±0.0046
Sigmoid	98.13±0.41	92.57±3.78	97.02±0.76	0.9899±0.0049

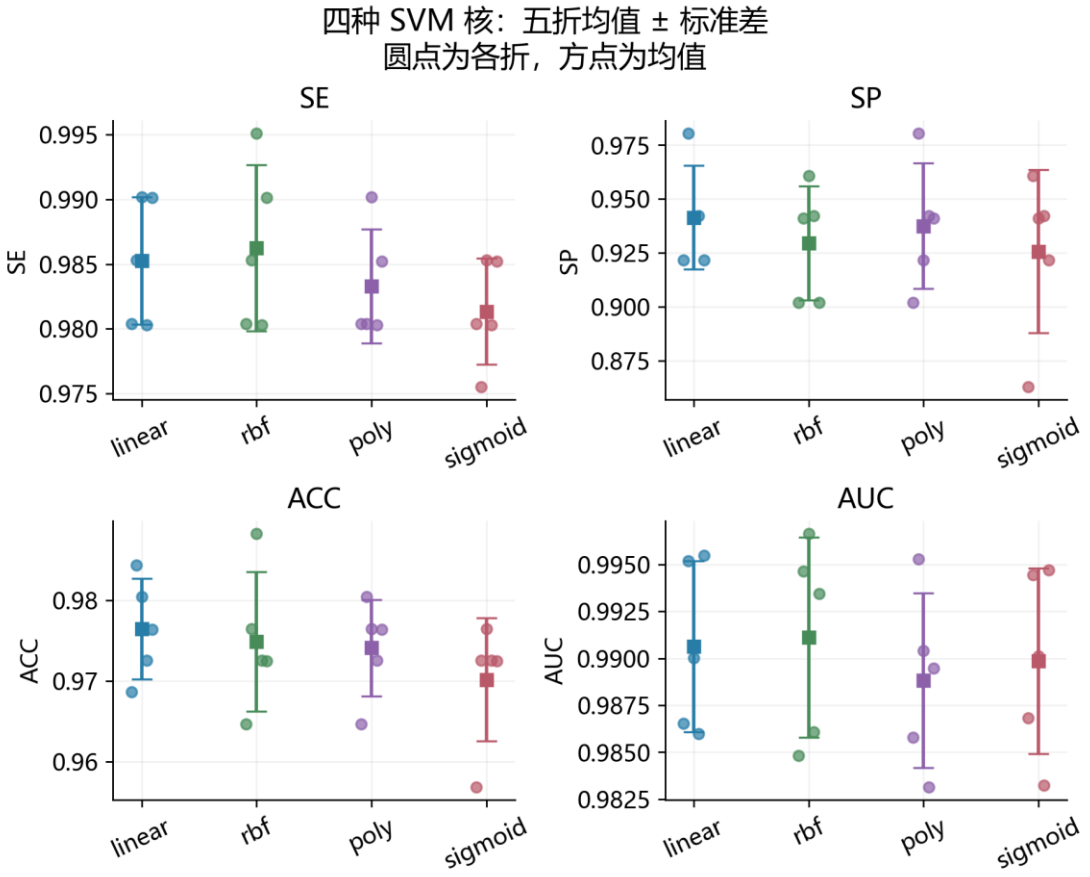


图 4-1 各核的逐折指标与均值、标准差

4.4 核函数效果的讨论

线性核的结果首先提示我，标准化后的四特征已经包含较容易用线性边界区分的信息。它的平均 AUC 只比 RBF 低约 0.0005，ACC 反而略高；OOF 总误

判 30 条，RBF 为 32 条。因此，当前结果不支持“边界越复杂就一定越好”的判断。这里也不能反过来断言数据完全线性可分，因为线性核仍然存在误判。

RBF 的 SE 略高，但 SP 比线性核低 1.18 个百分点。具体来说，RBF 比线性核少错判 1 名男生，却多错判 3 名女生。这表明它在 0 阈值处的取舍更偏向男生，而较高 AUC 说明跨阈值的总体排序略有优势。内层五次联合选核均选中了 RBF，因此主比较中的 SVM（内层选核）恰好与本次 RBF 行一致；这是一项实际选择结果，并非预先强制使用 RBF。其五折（C，γ）依次为（1，0.1）、（0.1，0.1）、（1，0.1）、（1，0.1）、（0.1，0.25），较大的 C 和 γ 没有在这些折中被选中。

三次多项式核的平均 ACC 为 97.41%、AUC 为 0.9888，在本次候选范围内没有优于线性核。多项式交互增加了模型表达形式，但并未带来稳定的外层收益；当前数据不能说明这种差异究竟来自核的形状、固定阶数还是搜索范围，因此不把它概括为多项式核普遍较差。其训练 AUC 均值约 0.9926，测试约 0.9888，提示仅观察训练拟合会高估实际表现。

Sigmoid 核的平均 ACC 最低，为 97.02%，SP 的折间标准差也最大，为 3.78 个百分点；第 1 折 7/51 名女生被错判，SP 只有 86.27%。但其平均 AUC 仍为 0.9899，高于多项式核的 0.9888。这再次说明较高排序指标与较少分类错误不是同一个目标。本实验没有进一步检查核矩阵谱，也没有扩大参数搜索，因而不能把这组结果简单解释为 Sigmoid 核的半正定性问题。

整体上，四个核的 ACC 差异不足 0.7 个百分点，AUC 均接近 0.99。我的结论是：线性核已经是有效的比较基准，RBF 在当前内层 AUC 选择规则下更常被选中；选择哪种核，还取决于更重视排序还是固定阈值处的类别错误。

五、两种方法的对比与误判分析

5.1 整体性能与逐折配对比较

表 5-1 直接比较 MLP 与 SVM（内层选核）。MLP 的 ACC 高 0.16 个百分点、SP 高 1.57 个百分点；SVM 的 SE 高 0.20 个百分点、AUC 高 0.0012。差异方向随指标变化，没有一个方法在四项指标上同时占优。

表 5-1 两种完整训练流程的外层五折结果

方法	SE（%）	SP（%）	ACC（%）	AUC
MLP-BP	98.43±0.41	94.53±2.14	97.65±0.62	0.9900±0.0038
SVM-selected	98.62±0.64	92.96±2.64	97.49±0.86	0.9911±0.0053

我进一步按相同测试折进行配对，而不是只看均值。表 5-2 中，SVM 在第 3 折的 AUC 比 MLP 高 0.00625，但在第 1、2、4 折都略低；五折中仅有两折 AUC 更高。第 3 折的较大增益拉高了均值，却不代表它在每组样本上都有优势。ACC 方面，SVM 一折更高、一折相同、三折更低。

表 5-2 相同测试折上的差值（SVM 减 MLP）

折	ΔSE（百分点）	ΔSP（百分点）	ΔACC（百分点）	ΔAUC
1	0.00	−1.96	−0.39	−0.00106
2	0.00	−3.92	−0.78	−0.00038
3	+0.98	+1.96	+1.18	+0.00625
4	0.00	0.00	0.00	−0.00047
5	0.00	−3.92	−0.79	+0.00145

五折训练集彼此重叠，这些差值也不是五次完全独立实验。因此，我将结果解释为当前划分下的接近表现与阈值取舍，不据此声称统计显著的优越性。图 5-1 给出了两种方法的 OOF 混淆矩阵：MLP 总错 30 条，SVM 总错 32 条。SVM 比 MLP 少错判 2 名男生，却多错判 4 名女生，这正是“SE 略高、SP 较低、ACC 略低”的人数解释。

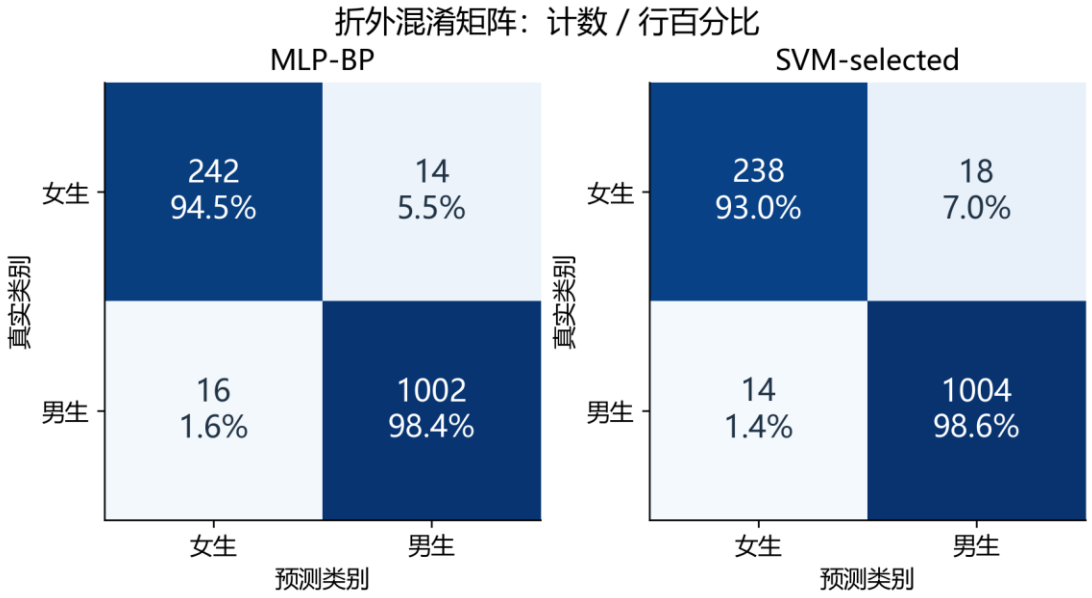


图 5-1 MLP 与 SVM 的 OOF 混淆矩阵，单元格显示人数及行百分比

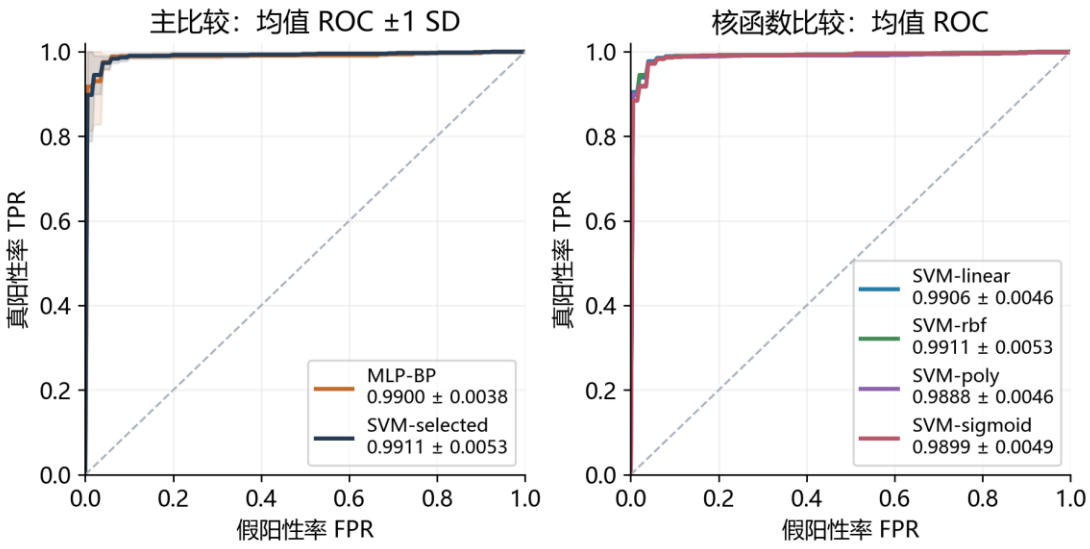


图 5-2 五折平均 ROC 曲线；左侧阴影为折间±1 标准差

图 5-2 中两种方法的平均 ROC 曲线接近，左上角附近均较快达到较高真阳性率。图例使用原始五个 AUC 的均值和标准差；曲线则由各折 ROC 在相同假阳性率网格上插值后平均得到。阴影只是各折曲线的波动，不能作为独立重复实验的置信带，也不能因为某段阴影重叠就得出显著性检验结论。

5.2 两种方法是否错在同一些样本上

我把两个模型的 OOF 结果逐条对齐，得到表 5-3。26 条样本被两种方法共同误判，占 MLP 全部 30 条误判的 86.7%，占 SVM 全部 32 条误判的 81.3%。只有 10 条样本属于“一种方法对、另一种方法错”。这说明替换分类器对少数样本确实有影响，但大部分错误是两种方法共有的。

表 5-3 两种方法的 OOF 错误重叠

判断情况	女生	男生	合计
两者均正确	237	1001	1238
仅 MLP 错误	1	3	4
仅 SVM 错误	5	1	6
两者均错误	13	13	26

共同误判的 13 名女生，其平均身高 167.92 cm、体重 58.54 kg、鞋码 39.50、50 m 成绩 7.87 s；共同判断正确的女生相应均值为 163.04 cm、51.68 kg、37.29 和 8.97 s。共同误判的女生在这些均值上更接近男生特征方向。共同误判的 13 名男生则平均身高 162.62 cm、体重 52.00 kg、鞋码 37.38、50 m 成绩 8.55 s，呈

现相反方向。这里按各列有效观测计算均值，比较仅用于描述，不能由此断定标签有误。

我又查看了具体记录。匿名行号 row_0022 的标签为男生，四特征为（156 cm，47 kg，36 码，9.5 s），两种方法均判为女生；row_0089 的标签为女生，特征为（166 cm，56 kg，40 码，8.5 s），两者均判为男生。这些例子帮助我理解，模型依据的是四特征的组合模式，无法仅凭当前输入保证每个人都被正确识别。特征重叠、测量误差和标签噪声都可能产生这类现象，目前证据不能区分它们各自的影响。

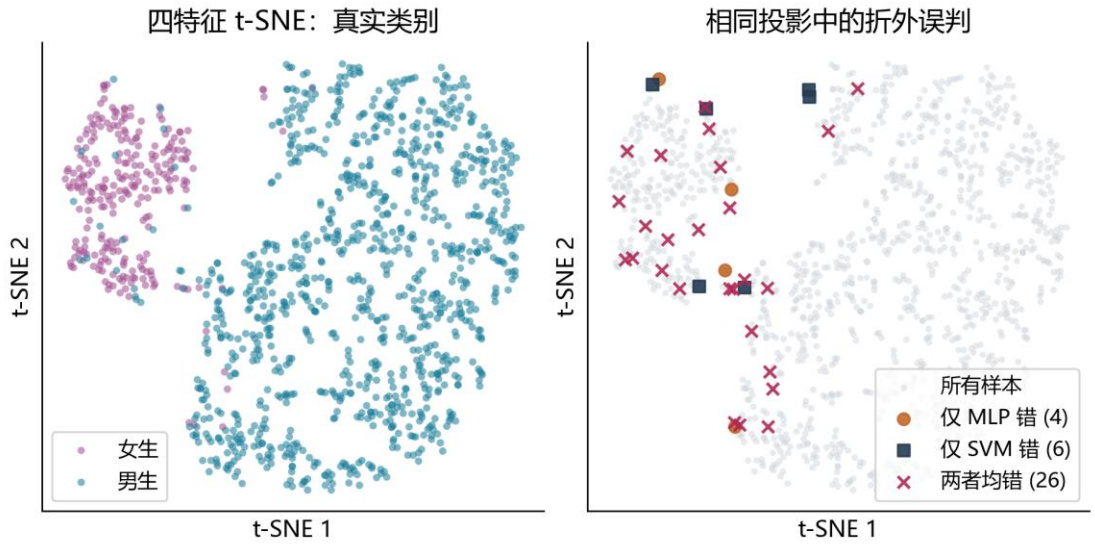


图 5-3 四特征的 t-SNE 描述性投影与相同坐标上的 OOF 误判

图 5-3 左侧可以看到两个主要类别区域，以及少量落在另一类区域中的样本；右侧将共同误判与各方法单独误判叠加到相同坐标。这个图与前面的错误重叠统计相互补充，但二维图并不是模型实际使用的决策空间。t-SNE 只在原始四特征经独立填补、标准化后作描述性降维，既不输入分类器，也不参与调参或指标计算；投影中的间距和区域形状不能当作分类性能的定量证明。

t-SNE 的困惑度设为 30，采用 PCA 初始化和自动学习率，迭代 1000 次，随机种子为 23。图中标签只用于着色，错误标记来自已经完成的 OOF 预测。

5.3 结果适用范围

本次结论来自同一份课程数据和一次固定随机种子的嵌套五折。输入质量规则保留了范围内极端值，且缺少更细的个体来源信息；有限的参数网格也不能覆盖所有可能的 MLP 或 SVM 设置。因此，结果支持“在当前四特征、数据和评价流程下两者均有效”，不能推出在其他人群或参数范围中同样排序。

如果继续实验，我会优先增加独立数据或重复外层划分，检查这个很小的差异是否稳定；若任务更重视女生识别，再在训练数据内部评估类别权重或阈值调整。目前报告中的数字只对应已经执行的实验，这些后续方案没有计入结果。

六、实验总结与体会

本实验完成了手写 4–3–1 BP 网络和四核 SVM 的分类实现，并用同一套五折评价比较其表现。手写 BP 的梯度校验与训练曲线使我能够把链式求导、参数更新和实际收敛联系起来；SVM 的核比较则表明，非线性形式增加了可选边界，但并不会自动带来更少的测试错误。

在主比较中，MLP 的平均 ACC 为 97.65%、AUC 为 0.9900；内层选核 SVM 的平均 ACC 为 97.49%、AUC 为 0.9911。对我而言，比这几个均值更有价值的是它们背后的差异：MLP 在默认阈值下的女生召回率较高，SVM 的平均排序略高，而 26 条共同误判说明两者面对不少相同的困难样本。因此，评价分类器应同时考虑排序能力、两类错误及划分波动，不能把一个略高的指标当作全面更好的证据。

Notebook 保存了完整实现、运行输出和结果图表；五折划分、候选搜索分数、逐条 OOF 预测与数据文件哈希同时保存于 results/homework2，便于复核报告中的统计量。实验使用 Python 3.10.19、NumPy 2.2.6、scikit-learn 1.7.2，基础随机种子为 23。

参考文献

[1] scikit-learn developers. Nested versus non-nested cross-validation[EB/OL]. scikit-learn 1.7.2 documentation. https://scikit-learn.org/1.7/auto_examples/model_selection/plot_nested_cross_validation_iris.html（访问日期：2026-10-13）.

[2] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. Nature, 1986, 323: 533–536. DOI: 10.1038/323533a0.

[3] Cortes C, Vapnik V. Support-vector networks[J]. Machine Learning, 1995, 20: 273–297. DOI: 10.1007/BF00994018.

[4] scikit-learn developers. SVC[EB/OL]. scikit-learn 1.7.2 documentation. https://scikit-learn.org/1.7/modules/generated/sklearn.svm.SVC.html（访问日期：2026-10-13）.

[5] LIBSVM authors. LIBSVM FAQ: How do I choose the kernel?[EB/OL]. https://www.csie.ntu.edu.tw/~cjlin/libsvm/faq.html（访问日期：2026-10-13）.